



## Resum IS

Informació i Seguretat (Universitat Autònoma de Barcelona)

# INFORMACIÓ I SEGURETAT


## Índex de continguts

<b>Tema 1 .....</b>	<b>2</b>
Motivació. Planteig dels problemes de la comunicació.....	2
<b>Tema 2 .....</b>	<b>3</b>
Conceptes bàsics de la teoria de la informació .....	3
<b>Tema 3 .....</b>	<b>5</b>
Codificació de la font .....	5
<b>Tema 4 .....</b>	<b>7</b>
Compressió de la font .....	7
<b>Tema 5 .....</b>	<b>8</b>
Codificació del canal .....	8
<b>Tema 6 .....</b>	<b>9</b>
Teoria de la Codificació per a la correcció d'errors .....	9
<b>Tema 7 .....</b>	<b>11</b>
Criptografia bàsica i seguretat computacional .....	11

# Tema 1

## Motivació. Planteig dels problemes de la comunicació

### Model d'un sistema de comunicació




### Problema de la comunicació

Eficient: Minimitzant recursos (espai i temps).

Exacta: Sense pèrdua d'informació.

Segura: Sense manipulació de la informació.


### Arquitectura d'un sistema de comunicació




- **Font:** persona o màquina que produeix informació.
- **Emisor/Codificador:** adapta la informació a les característiques del canal (seq. dígit, polsos elèctrics,...).
- **Canal:** mitjà pel qual es transmet el missatge (espai, fil, disc,...).
- **Soroll:** error (pertorbació) aleatori característic del canal.
- **Receptor/Decodificador:** recuperació de la informació, sovint amb errors.
- **Destí:** persona o màquina que rep la informació.

### Espies: privacitat i autenticitat

**Privacitat:** preservar la confidencialitat de les dades (espia passiu).



**Autenticitat:** impedir la modificació no autoritzada de les dades (espia actiu).



## Tema 2

### Conceptes bàsics de la teoria de la informació

La quantitat d'informació que obtenim després de realitzar l'experiment és igual a la quantitat d'incertesa abans de realitzar-ho.

$$\text{Quantitat d'informació} = \text{Quantitat d'incertesa.}$$

**Mesura de Hartley** : Incertesa sobre  $n$  resultats possibles i equiprobables.

$$I(n) = \log(n)$$

**Problema**: no es tenen en compte les probabilitats de cada resultat

**Mesura de Shannon**: Incertesa/informació d'un esdeveniment  $A$  amb probabilitat  $p(A)$

$$I(A) = \log \frac{1}{p(A)} = -\log p(A)$$

**Entropia**: És la magnitud que mesura la informació continguda en un flux de dades, o d'una font.

$$H(X) = \sum (p(a_i) \cdot I(A_i)) = \sum \left( p(a_i) \cdot \log \frac{1}{p(a_i)} \right)$$

↳ Unitats de l'entropia  
bits/resultat o bé bits/missatge

**NOTA**:  $\log_2 \rightarrow$  Perquè volem els resultats en bits

#### Entropia d'una variable aleatòria

Quantitat d'informació mitjana que té una font d'informació.

$$H(X) = -\sum (p_i \cdot \log p_i)$$


Propietats:

$$\begin{cases} H(X) \geq 0 \\ H(X) = 0 \text{ si hi ha una } p_i = 1 \\ H(X) \leq \log n \\ H(X) = \log n \text{ si } p_i = 1/n \forall_i \end{cases}$$

#### Entropia binària

Entropia d'una font que emet zeros i uns.

Si tenim 2 esdeveniments:



$$S = \{a_1, a_2\} \begin{pmatrix} p(a_1) = p. \\ p(a_2) = 1 - p \end{pmatrix}$$

$$H(X) = p \cdot \log \frac{1}{p} + (1 - p) \cdot \log \frac{1}{(1 - p)}$$

↳ Com a màxim serà 1 bit.

### Entropia conjunta

Tenim que  $X, Y$  son variables aleatòries discretes que representen entrada i sortida d'un canal.

$$H(X, Y) = - \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \cdot \log p(x_i, y_j)$$

### Entropia condicionada

Donat un valor  $Y = y$  obtenim  $X$

$$H(X|Y) = - \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \cdot \log p(x_i | y_j)$$

### Informació mútua

Mesura la dependència mútua de dues variables aleatòries, és a dir, la reducció d'incertesa (entropia) d'una variable aleatòria  $X$ , donat el coneixement del valor d'una altre variable aleatòria  $Y$ .

$$I(X, Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$$

### Capacitat del canal

Quantitat màxima d'informació que pot passar per símbol d'entrada. Unitat de mesura bits/símbol.

$$C = \max(I(X, Y)) = \max(H(X) - H(Y|X))$$

## Tema 3

### Codificació de la font

Conjunt de missatges:

$$S = \{a_1, \dots, a_n\}$$

Alfabet D-ari del codi

$$A = \{\sigma_1, \dots, \sigma_n\}$$

Ex. Alfabet Binari/2-ari

$$A = \{0, 1\}$$

Codi

$$C = \{c_1, \dots, c_n\}$$

#### Codis de Longitud Fixa

Alguns exemples en poden ser l'ASCII o UNICODE

$$D^L \geq n \quad L \geq \frac{\log n}{\log D}$$

$$\begin{bmatrix} L \rightarrow \text{Longitud} \\ D \rightarrow \text{Símbols} \\ n \rightarrow \text{paraules} - \text{codi} \end{bmatrix}$$

Si codifiquem seqüència de símbols (m-tuples de missatges):

$$D^L \geq n^m \quad L \geq \frac{m \cdot \log n}{\log D}$$

#### Codis de Longitud Variable

Alguns exemples en poden ser el Morse o Zip. Només treballarem amb codis de descodificació única.

$$\text{Longitud mitjana} = \bar{L} = \sum_{i=1}^n p_i L_i$$

#### Codis instantanis

Un codi és instantani si cap paraula-codi és prefix d'una altra. Tot codi instantani és de descodificació única, però no a l'inrevés.

Per comprovar si existeix un codi instantani utilitzem el teorema de Desigualtat de KRAFT.

$$\sum_{i=1}^n D^{-L_i} \leq 1$$

#### Primer Teorema de Shannon

Estableix el límit teòric per a la compressió d'una font de dades (origen).

Per a obtenir aquest mínim valor de la Longitud mitjana utilitzem:

$$\bar{L} \geq \frac{H(S)}{\log D}$$

#### Eficiència i redundància d'un codi

L'eficiència d'un codi D-ari amb longitud mitjana  $\bar{L}$  per a un conjunt de missatges  $S$  és:

$$\eta = \frac{H(S)}{\bar{L} \cdot \log D} (\leq 1)$$

La redundància és el valor complementari de l'eficiència.

$$1 - \eta (\geq 0)$$

### Codi òptim

Un codi és òptim si per el mateix conjunt de missatge només existeixen altres codis amb longitud mitjana  $\bar{L}$  igual o superior.

- Si  $\eta = 1$  aleshores és òptim.
- Si comparem codis D-aris pel mateix conjunt de missatges  $S$ 
  - o Comparem les longituds mitjanes  $\bar{L}$
- Si comparem codis D-aris amb diferent alfabet.
  - o Comparem les eficiències

### Construcció de codis òptims (Mètode Huffman)

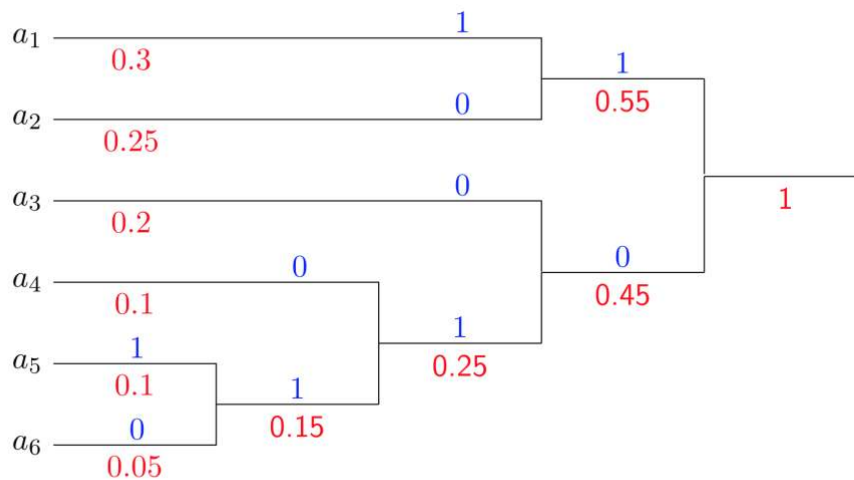
És un mètode vàlid per a qualsevol alfabet.

#### **Algorisme:**

1. Ordenem els missatges de  $S$  per ordre decreixent de possibilitats.
2. Assignem 1 i 0 com a últims símbols de les paraules-codi per als dos missatges menys probables ( $a_{n-1}$  i  $a_n$ ).
3. Reagrupem els dos últims missatges com un nou missatge amb probabilitat  $p_{n-1} + p_n$
4. Si queda més d'un missatge tornem a 1.

#### Exemple Huffman

L'arbre resultant representa el codi de Huffman òptim.



$$C = \{11, 10, 00, 010, 0111, 0110\}$$

## Tema 4

### Compressió de la font

#### Taxa de compressió

Suposem un fitxer  $M$  comprimit a un fitxer  $C$ , la seva taxa de compressió serà la mida del fitxer comprimit dividida entre la mida del fitxer no comprimit, on aquesta taxa estarà mesurada en bits per bit (bpb).

$$R = \frac{|C|}{|M|}$$

#### Percentatge de compressió

En aquest cas el tant per cent % de compressió del fitxer vindrà donat per:

$$(1 - R) \cdot 100\%$$

#### Bitrate

També anomenada *taxa de bits*, és la freqüència amb que les dades es transmeten en el medi. Es mesura en bits per símbol.

$$BR = \frac{|C| \text{ bits}}{|M| \text{ símbols}}$$

#### Mètodes de compressió

- **Per Taxa de Compressió**
  - o Sense pèrdua (lossless): És totalment reversible  $I = \hat{I}$
  - o Amb pèrdua (lossy): No és totalment reversible  $I \neq \hat{I}$
- **Per Model**
  - o Estàtics (no adaptatius): el model d'estimació és fix durant tot el procés de compressió.
  - o Dinàmics (adaptatius): el model canvia durant al procés de compressió

#### Tècniques de compressió

- **Basats en repetició** → RLE. Elimina redundància quan la font repeteix molts missatges
- **Mètodes estadístics** → Huffman, aritmètic. Elimina la redundància estimant les probabilitats dels missatges.
- **Basats en diccionari** → LZ, LZW. Elimina la redundància creant un diccionari de missatges més freqüents.
- **Basats en transformades** → DCT, Wavelets, JPG. Transforma missatges per descorrelacionar les dependències estadístiques.

*Cal mirar els procediments dels exercicis per a saber fer:*

***RLE, Codificació Aritmètica, Lempel – Ziv(LZ77 i LZ78)***

#### Compressió d'imatges

- Mètodes més usuals
  - o Sense Compressió: BMP, RAW, PGM, PPM
  - o Sense Pèrdua: PNG, GIF, TIFF
  - o JPEG
  - o JPEG2000
  - o MPEG



## Tema 5

### Codificació del canal

#### Tipus de Canals

- Canal Sense Pèrdua
  - $H(B|A) = 0 \rightarrow I(A, B) = H(A)$
  - $n \leq m$
  - Cada columna de  $\Pi$  té un únic element  $\neq 0$
  - $C = \max_{\{p_i\}_{i=1}^n} H(A) = \log n$
- Canal Determinista
  - $H(B|A) = 0 \rightarrow I(A, B) = H(B)$
  - $m \leq n$
  - Cada fila de  $\Pi$  hi ha un únic element  $\neq 0$
  - $C = \max_{\{p_i\}_{i=1}^n} H(B) = \log m$
- Canal Sense Soroll
  - És sense soroll si és *Sense Pèrdua* i *Determinista*
  - $I(A, B) = H(A) = H(B)$
  - A cada columna de  $\Pi$  hi ha un 1 i la resta 0
  - $n = m$
  - $C = \log n = \log m$
- Canal Totalment Simètric
  - Les files i les columnes de  $\Pi$  són iguals excepte canvi d'ordre.
  - $C = \log m - H$  on  $H = H(B|A)$
- Canal amb Entrada i Sortida Independents
  - $H(A|B) = H(A)$  i  $H(B|A) = H(B)$   
 $\hookrightarrow I(A, B) = 0$
  - No serveix per transmetre informació
  - Les files de  $\Pi$  són idèntiques
  - $C = 0$

Matriu del canal:

$$\Pi = \begin{pmatrix} \frac{1}{2} & 0 & \frac{1}{2} \\ 0 & 1 & 0 \end{pmatrix},$$

$C = \log 2 = 1$  bits/símbol entrada

Matriu del canal:

$$\Pi = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 1 \end{pmatrix},$$

$C = \log 2 = 1$  bits/símbol entrada

Matriu del canal:

$$\Pi = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix},$$

$C = \log 2 = 1$  bits/símbol entrada

Matriu del canal:

$$\Pi = \begin{pmatrix} \frac{1}{3} & \frac{1}{3} & \frac{1}{6} & \frac{1}{6} \\ \frac{1}{6} & \frac{1}{6} & \frac{1}{3} & \frac{1}{3} \end{pmatrix},$$

$C = \log 4 - H\left(\frac{1}{3}, \frac{1}{3}, \frac{1}{6}, \frac{1}{6}\right) = 0.081$  bits/símbol entrada

Matriu del canal:

$$\Pi = \begin{pmatrix} \frac{1}{4} & \frac{1}{4} & \frac{1}{2} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{2} \end{pmatrix},$$

$C = 0$  bits/entrada

#### Probabilitat mitjana d'error

$$\overline{p_e} = \sum_{j=1}^m p(B_j) p_e(B_j) = 1 - \sum_{j=1}^m p(f(B_j), B_j)$$

#### Regla MPE (Mínima Probabilitat d'Error)

Aquesta regla minimitza la probabilitat mitjana d'error.

#### Regla a MV (Màxima Versemblança)

En un canal amb distribució inicial de probabilitat equiprobable, les regles MPE i MV coincideixen.

#### Exercicis que cal mirar:

MPE en un BSC

BSC – Codificació de la font

BSC – Regla MPE o MV

BSC – Probabilitat mitjana d'error

BSC – Taxa de transmissió de la informació

## Tema 6

### Teoria de la Codificació per a la correcció d'errors

<b>Símbol</b>	<b>Descripció</b>
$\mathbb{F}$	<u>Alfabet</u> del canal, en codis binaris $\mathbb{F} = \{0,1\}$
$v, u$	<u>Paraula</u> , és una seqüència de dígit binaris $v = (v_1 v_2 \dots v_n) \in \mathbb{F}^n$
$n$	<u>Longitud</u> de la paraula
$C$	<u>Codi Binari</u> , és un subconjunt de paraules de longitud $n$ , és a dir $C \subset \mathbb{F}^n$
$M$ o $ C $	Número de <u>paraules</u>
$R_T$	<u>Taxa de transmissió</u> de la informació $R_T = \frac{\log_2( C )}{n}$ bits/símbol
$r$	<u>Redundància</u> $r = 1 - R_T$
$p$ // $\bar{p}$	<u>Probabilitat</u> d'error // Probabilitat mitjana d'error
$d_H$	<u>Distància Hamming</u> . $d_H(u, v) =  \{i \mid u_i \neq v_i, 1 \leq i \leq n\} $
$d$	<u>Distància mínima</u> . $d = \min\{d_H(u, v) \mid u \neq v, u, v \in C\}$

<i>CODI BINARI</i> $C[n, M, d]$		
$C[3, 2, 3]$	$C = \{000, 111\}$ ( $v = 000$ $u = 111$ )	$n = 3, M = 2, d = 3$
$C[6, 4, 3]$	$C = \{000000, 010101, 101010, 111111\}$	$n = 6, M = 4, d = 3$

<i>Símbol</i>	<i>Descripció</i>	
<i>t</i>	<u>Capacitat Correctora</u> $t = \left\lfloor \frac{d-1}{2} \right\rfloor$ (←No agafem decimals) $t = \left\lfloor \frac{4-1}{2} \right\rfloor = \left\lfloor \frac{3}{2} \right\rfloor = 1$	
<i>δ</i>	<u>Capacitat Detectora</u> $\delta = d - 1$	
<i>Sigui <b>C</b> un <u>codi binari</u> de distància mínima <b>d</b></i>		
Podem detectar <i>r</i> errors	<i>si, i només si</i>	<i><b>r &lt; d</b></i>
Podem corregir <i>t</i> errors		<i><b>2t &lt; d</b></i>
Podem corregir <i>s</i> esborralls		<i><b>s &lt; d</b></i>
Podem corregir <i>t</i> errors i <i>s</i> esborralls		<i><b>2t + s &lt; d</b></i>

## Propietats dels codis binaris lineals

<b>Símbol</b>	<b>Descripció</b>
<b>Codi Lineal</b> $C[n, k, d]$	Codi binari $C$ on per tota parella $u, v \in C$ aleshores $u + v \in C$ . És a dir, $C \subset \mathbb{F}^n$ és un subespai vectorial de $\mathbb{F}^n$
Per a que un codi sigui lineal: <ul style="list-style-type: none"> <li>• Ha de tenir la paraula tot zeros. <math>\mathbf{0} = (0 \dots 0)</math></li> <li>• Ha de tenir <math>2^k</math> paraules-codi. <math>M =  C  = 2^k, k \leq n</math></li> <li>• La suma de tota parella de paraules codi ha de ser una altra paraula codi. <math>(u + v) \in C</math> (Suma és bit a bit)</li> </ul>	
$k$	<u>Dimensió</u> de $C$ com a subespai vectorial de $\mathbb{F}^n$ $k = \log( C )$
$d$	Pes mínim, és a dir, nombre mínim d'1s.
<u>Producte escalar de dos vectors</u> ( $u \cdot v$ ) $u = (1, 0, 1) \quad v = (1, 1, 0) \rightarrow (1 \cdot 1) + (0 \cdot 1) + (1 \cdot 0) = u \cdot v = 1$ $u = (1, 0, 1, 0) \quad v = (0, 1, 0, 1) \rightarrow (1 \cdot 0) + (0 \cdot 1) + (1 \cdot 0) + (0 \cdot 1) = u \cdot v = 0$	
$C^\perp$	<u>Codi Ortogonal</u> , producte escalar de dos paraules = 0 ( $u \cdot v = 0$ ) Tots els vectors amb número parell d'1s és ortogonal amb ell mateix. $C^\perp[n, n - k, d']$
$C'$	<u>Codi Estès</u> , $C[n + 1, k, d^*]$
$G$	<u>Matriu generadora</u> del codi $C$ , en què les $k$ files de la matriu formen una base de $C$ . (Una base de $C$ son diferents paraules-codi linealment independents) $G = \left( \underbrace{\quad\quad\quad}_n \right) \Bigg]_k$
$H$	<u>Matriu de control</u> $G = (Id x) \rightarrow H = (x^t Id)$ $G = (x Id) \rightarrow H = (Id x^t)$ És probable que sigui necessari aplicar transformacions lineals a la nostra $G$ perquè aquesta quedi amb la Identitat.

<b>CODI BINARI LINEAL</b> $C[n, k, d]$		
$C[3, 2, 1]$	$C = \{000, 001, 010, 011\}$	$n = 3, k = 2, d = 1, R_T = \frac{2}{3}$

<b>CODIFICAR AMB UN CODI LINEAL</b> $C[5, 3, 2]$		
<u>Missatge</u> $u = (101)$	<u>Matriu Generadora</u> $G = \begin{pmatrix} 1 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 1 & 1 \\ 0 & 0 & 1 & 0 & 1 \end{pmatrix}$	$u \cdot G = (101) \cdot \begin{pmatrix} 1 & 0 & 1 & 1 & 0 \\ 0 & 1 & 0 & 1 & 1 \\ 0 & 0 & 1 & 0 & 1 \end{pmatrix} = (10011)$

<b>LA SÍNDROME</b>	
Donat $w \in \mathbb{F}^n$ , el vector $H(w) = w \cdot H^T \in \mathbb{F}^{n-k}$ s'anomena síndrome de $w$ .	
$e$	<u>Vector d'error</u> . Si enviem $v \in C$ i rebem $w \in \mathbb{F}^n$ , el vector d'error és $e = w - v$

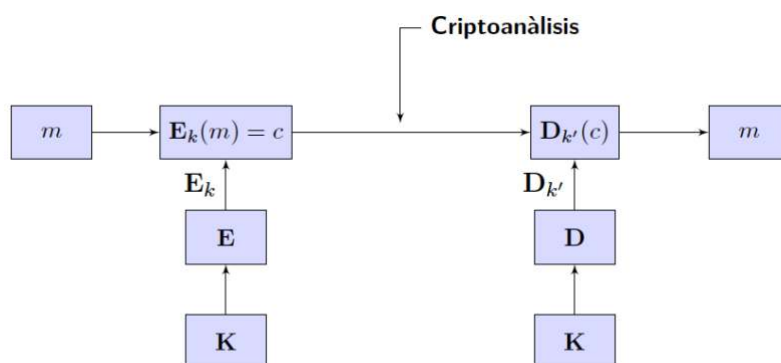
<b>CALCULAR DISTANCIA MÍNIMA A PARTIR DE LA MATRIU DE CONTROL</b>
Si hi ha columna tot 0's $d = 1$ , sinó:
Si hi ha 2 columnes iguals $d = 2$ , sinó:
Si la suma de 2 columnes ens dona una altra (3 dependents) $d = 3$ , sinó:
Si la suma de 3 columnes dona una altra (4 dependents) $d = 4$ .

## Tema 7

### Criptografia bàsica i seguretat computacional

#### Criptografia de Clau Pública

Mètode de xifratge en el qual les claus per xifrar i desxifrar no són deduïbles fàcilment una de l'altra.

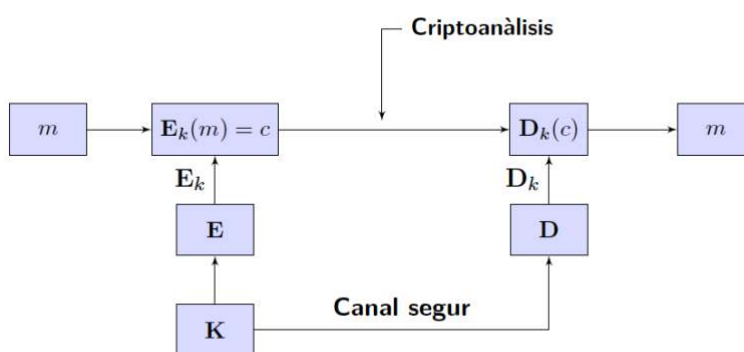


#### Criptografia de Clau Simètrica (Compartida o Privada)

Mètode de xifratge en el qual els claus per xifrar i desxifrar (que comparteixen emissor i receptor) són fàcilment deduïbles una de l'altra.

S'anomenen també mètodes de clau compartida o secreta.

$$\begin{aligned} E_k(m) &= c, & D_k(c) &= m \\ D_k(E_k(m)) &= m, & E_k(D_k(c)) &= c \end{aligned}$$



Aquest tema és millor aprendre'l fent exercicis.